Laporan Analisis Association Rule: Dataset Online Retail

Tugas Data Mining · Muhammad Zaki Nanda Wahyudi (5054251007)

1. Eksplorasi dan Pembersihan Data

Dataset mentah berisi 541.909 baris dan 8 kolom (InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, Country), dengan 25.900 invoice dan 4.223 deskripsi produk unik. Sebagian besar baris (495.478) berasal dari United Kingdom. Dua kolom memiliki nilai kosong: Description (1.454 baris) dan CustomerID (135.080 baris). Hanya InvoiceNo dan Description yang relevan untuk association rule, karena keduanya mendefinisikan transaksi dan item. CustomerID tidak dipakai sehingga kekosongannya tidak memengaruhi analisis.

Pembersihan dilakukan dalam tiga langkah berikut.

Langkah	Baris dihapus	Sisa baris
Data awal	-	541.909
Hapus Description kosong	1.454	540.455
Hapus invoice batal (awalan "C")	9.288	531.167
Hapus Quantity ⩽ 0	474	530.693

Total 11.216 baris dibuang. Jumlah invoice turun dari 25.900 menjadi 20.136 (3.836 di antaranya adalah invoice pembatalan), dan jumlah produk unik dari 4.223 menjadi 4.077. Satu transaksi rata-rata memuat sekitar 26 baris produk (median 15). Data kemudian diubah menjadi matriks one-hot berukuran 20.136 transaksi × 4.077 produk.

2. Pemilihan Parameter

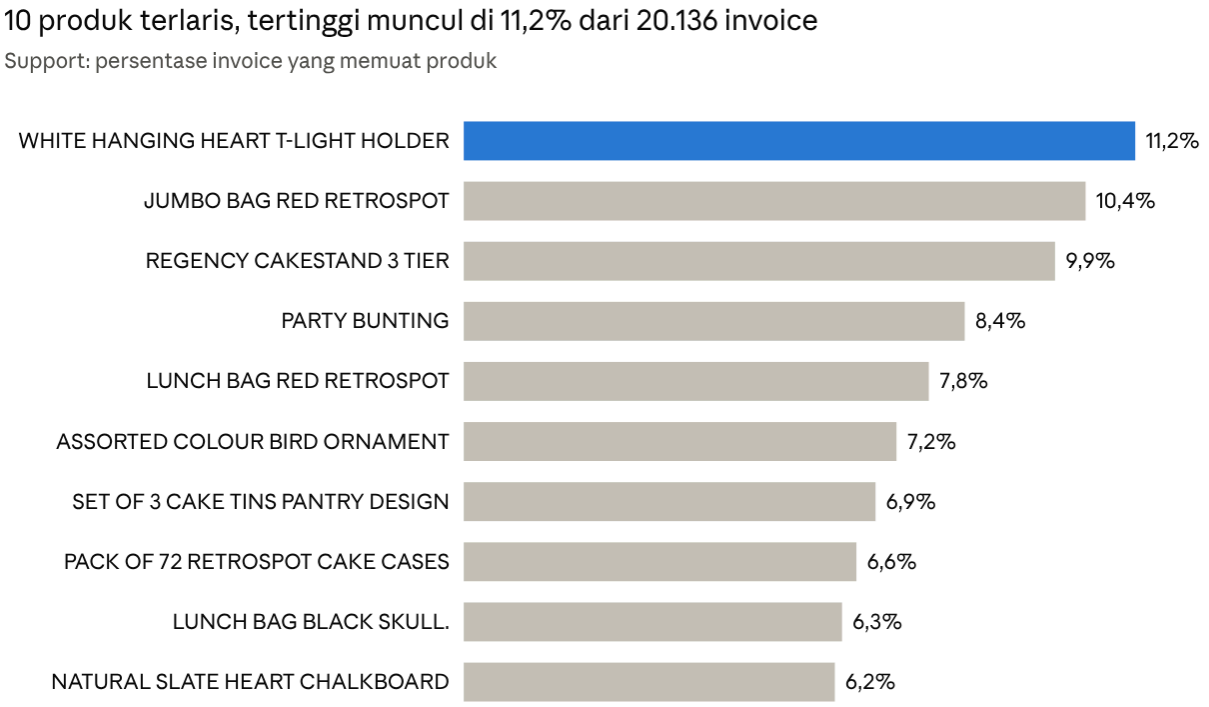
Parameter awal min_support 0,01 dan min_confidence 0,5 menghasilkan 841 rules, terlalu banyak untuk diinterpretasi satu per satu dan banyak yang hanya variasi dari kombinasi item yang sama. Lima kombinasi parameter kemudian dibandingkan (hanya rules dengan lift > 1).

min_support	min_confidence	Frequent itemset	Rules
0,01	0,5	1.854	841
0,015	0,5	694	177
0,02	**0,5**	**375**	**61**
0,015	0,6	694	94
0,02	0,6	375	31

Dipilih **min_support 0,02 dan min_confidence 0,5**. Jumlah 61 rules cukup untuk dianalisis tanpa membuang pola yang masih bermakna seperti pada confidence 0,6. Support 0,02 setara sekitar 400 transaksi, sehingga pola yang muncul cukup kuat dan bukan kebetulan dari beberapa invoice.

3. Frequent Itemset

Pada parameter terpilih terdapat 375 frequent itemset: 293 berisi satu produk, 79 berisi dua produk, dan 3 berisi tiga produk. Grafik berikut menunjukkan produk yang paling sering muncul dalam invoice.



Online_Retail.xlsx setelah pembersihan · 20.136 invoice

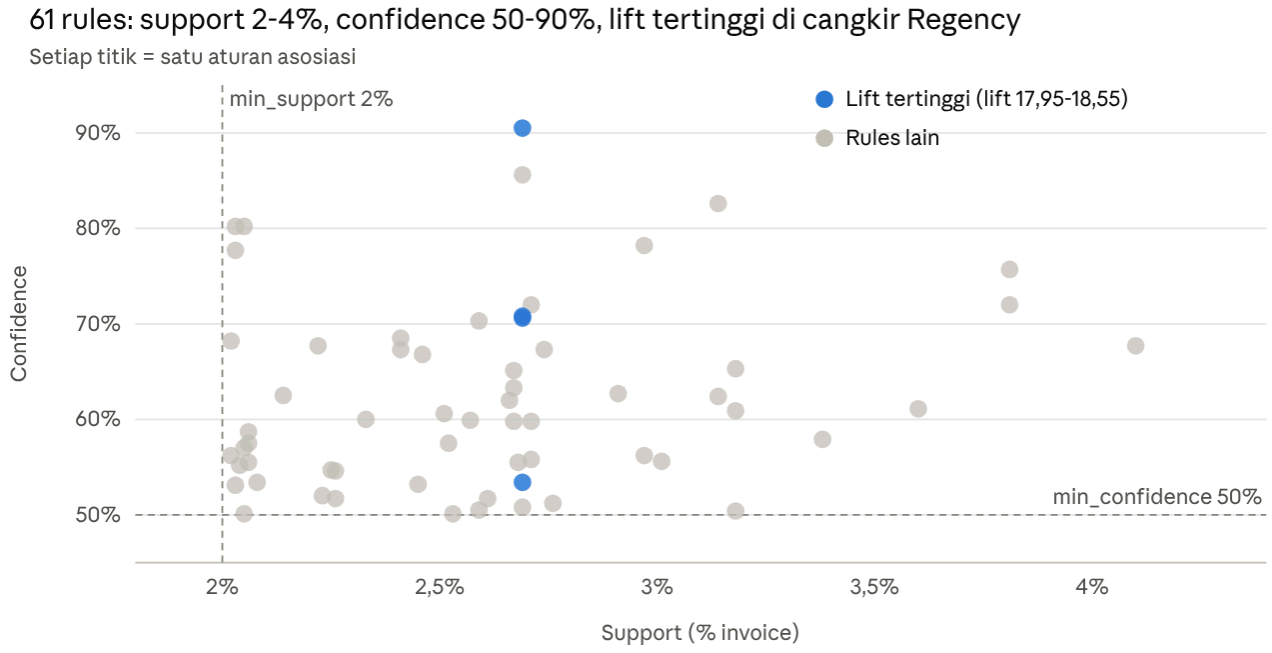
Itemset dua produk dengan support tertinggi adalah JUMBO BAG RED RETROSPOT bersama JUMBO BAG PINK POLKADOT (4,10%), disusul GREEN REGENCY TEACUP AND SAUCER bersama ROSES REGENCY TEACUP AND SAUCER (3,81%).

4. Aturan Asosiasi dan Evaluasi

Parameter terpilih menghasilkan 61 aturan dengan lift > 1. Ringkasan nilai evaluasinya:

Ukuran	Minimum	Rata-rata	Maksimum
Support	2,02%	2,61%	4,10%
Confidence	50,1%	62,4%	90,5%
Lift	5,08	10,99	18,55

Seluruh rules memiliki lift di atas 5, artinya pasangan produk tersebut dibeli bersama jauh lebih sering daripada jika dibeli secara independen. Grafik berikut memperlihatkan sebaran support dan confidence dari 61 rules.



FP-Growth, min_support 0,02, min_confidence 0,5 · 61 rules dengan lift > 1

Lima aturan dengan lift tertinggi:

Antecedent	Consequent	Support	Confidence	Lift	Conviction
PINK REGENCY TEACUP AND SAUCER	GREEN + ROSES REGENCY TEACUP AND SAUCER	2,69%	70,8%	18,55	3,29

Antecedent	Consequent	Support	Confidence	Lift	Conviction
GREEN + ROSES REGENCY TEACUP AND SAUCER	PINK REGENCY TEACUP AND SAUCER	2,69%	70,6%	18,55	3,27
PINK + ROSES REGENCY TEACUP AND SAUCER	GREEN REGENCY TEACUP AND SAUCER	2,69%	90,5%	17,95	9,98
GREEN REGENCY TEACUP AND SAUCER	PINK + ROSES REGENCY TEACUP AND SAUCER	2,69%	53,4%	17,95	2,08
PINK REGENCY TEACUP AND SAUCER	GREEN REGENCY TEACUP AND SAUCER	3,14%	82,6%	16,39	5,47

Evaluasi. Tiga aturan teratas berasal dari satu itemset yang sama, yaitu tiga cangkir Regency (Pink, Green, Roses) yang dibeli sebagai satu set. Aturan PINK + ROSES → GREEN paling kuat dari sisi confidence (90,5%) dan conviction (9,98): hampir semua pembeli dua warna pertama juga membeli warna ketiga. Aturan arah sebaliknya (GREEN → PINK + ROSES) lebih lemah karena Green juga sering dibeli bersama hanya satu warna lain. Dari 61 rules, 44 itemset berbeda terlibat, dan sebagian besar adalah varian satu seri produk: cangkir Regency, tas Jumbo (Apples/Pears, Red Retrospot/Pink Polkadot), tas Charlotte, lunch box (Spaceboy/Dolly Girl), dan alas berlutut Gardeners (Keep Calm/Cup of Tea). Satu pola lintas produk muncul pada REGENCY CAKESTAND 3 TIER bersama cangkir Roses yang mengarah ke cangkir Green (confidence 77,7%, lift 15,42).

5. Kesimpulan

- Pembersihan menghapus 11.216 baris (2,1% data) sehingga tersisa 20.136 transaksi valid dengan 4.077 produk.
- Dengan min_support 0,02 dan min_confidence 0,5, FP-Growth menemukan 375 frequent itemset dan 61 aturan asosiasi, seluruhnya bernilai lift > 5 (maksimum 18,55).
- Pola paling kuat adalah pembelian set tiga cangkir Regency (Pink, Green, Roses). Pola lain yang konsisten adalah pembelian beberapa varian warna atau desain dari satu seri produk yang sama.
- Secara bisnis, pola ini mendukung bundling set produk, penempatan varian satu seri secara berdekatan, rekomendasi "sering dibeli bersama" di toko online, dan penyediaan stok varian secara serempak.
- Keterbatasan: support rules hanya 2–4%, sehingga pola ini berlaku pada segmen pembeli yang spesifik, bukan seluruh pelanggan. Asosiasi menunjukkan keterkaitan pembelian, bukan sebab-akibat. Dataset juga didominasi pelanggan United Kingdom dan bisa mencakup pembeli grosir, sehingga pola belum tentu berlaku untuk ritel eceran.