# Laporan Analisis Performa Model Klasifikasi pada Dataset Transaksi *Imbalanced*

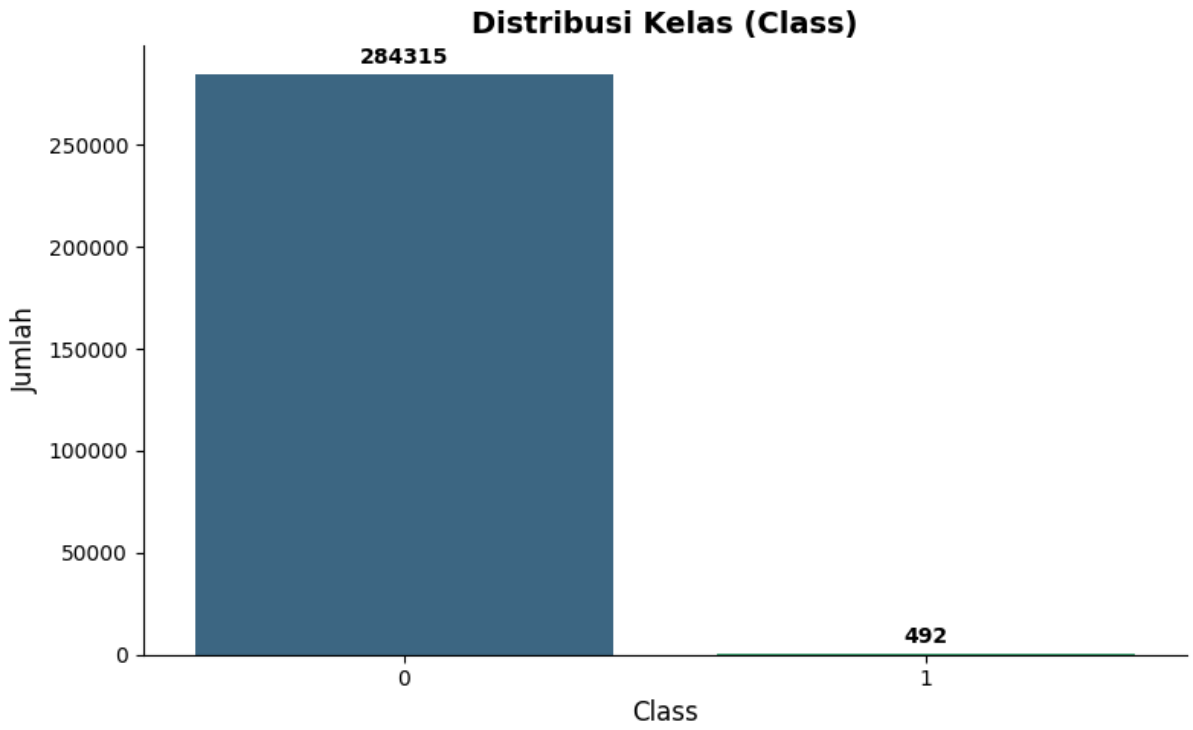
## 1. Pendahuluan & Eksplorasi Data Awal

Berdasarkan analisis struktur dataset yang digunakan, total data mencakup **284.807 baris** dan **31 kolom**, yang terdiri dari kolom waktu (Time), 30 fitur numerik berupa variabel transformasi PCA (V1 sampai V28), jumlah transaksi (Amount), serta variabel target (Class).

Dalam kasus deteksi penipuan (fraud detection), karakteristik data sangat tidak seimbang (imbalanced). Identifikasi distribusi pada atribut target Class menunjukkan hasil sebagai berikut:

- **Kelas 0 (Transaksi Normal):** 284.315 baris (99,83%)
- **Kelas 1 (Transaksi Fraud/Minoritas):** 492 baris (0,17%)

Visualisasi distribusi kelas awal dapat dilihat pada **Gambar 1**.




Gambar 1: Visualisasi distribusi kelas awal pada atribut Class, menunjukkan ketimpangan ekstrem antara kelas mayoritas (0) dan kelas minoritas (1)

**2. Pendekatan Penanganan Class Imbalance**

Untuk mengatasi masalah ketimpangan data, diterapkan langkah-langkah metodologis berikut:

- **Pembagian Dataset:** Dataset dibagi menjadi data latih dan data uji dengan rasio **80:20** menggunakan parameter stratify=y guna mempertahankan proporsi kelas minoritas yang konsisten pada kedua bagian data.
- **Penerapan SMOTE (Synthetic Minority Over-sampling Technique):** Metode oversampling ini digunakan untuk menambah jumlah sampel pada kelas minoritas secara sintetis.
- **Pencegahan Kebocoran Data (Data Leakage):** Resampling dengan SMOTE **hanya dilakukan pada data latih (**X_train **dan** y_train**)**, sementara data uji (X_test dan y_test) tetap dibiarkan murni menggunakan distribusi aslinya.

**3. Evaluasi Performa Model dan Analisis Perbandingan**

Dua algoritma ensemble method, yaitu **Random Forest** dan **Gradient Boosting**, diuji dalam dua kondisi berbeda (tanpa resampling dan dengan SMOTE). Performa masing-masing model pada kelas minoritas (fraud) dirangkum dalam tabel berikut:

| Model & Kondisi | Precision | Recall | F1-Score | AUC-ROC |
|---|---|---|---|---|
| **Random Forest (Tanpa Resampling)** | 0.9412 | 0.8163 | 0.8743 | 0.9630 |
| **Random Forest (SMOTE)** | 0.8351 | 0.8265 | 0.8308 | 0.9644 |
| **Gradient Boosting (Tanpa Resampling)** | 0.5294 | 0.1837 | 0.2727 | 0.3469 |
| **Gradient Boosting (SMOTE)** | 0.1845 | 0.8980 | 0.3061 | 0.7978 |

**Mengapa Akurasi Saja Tidak Cukup?**

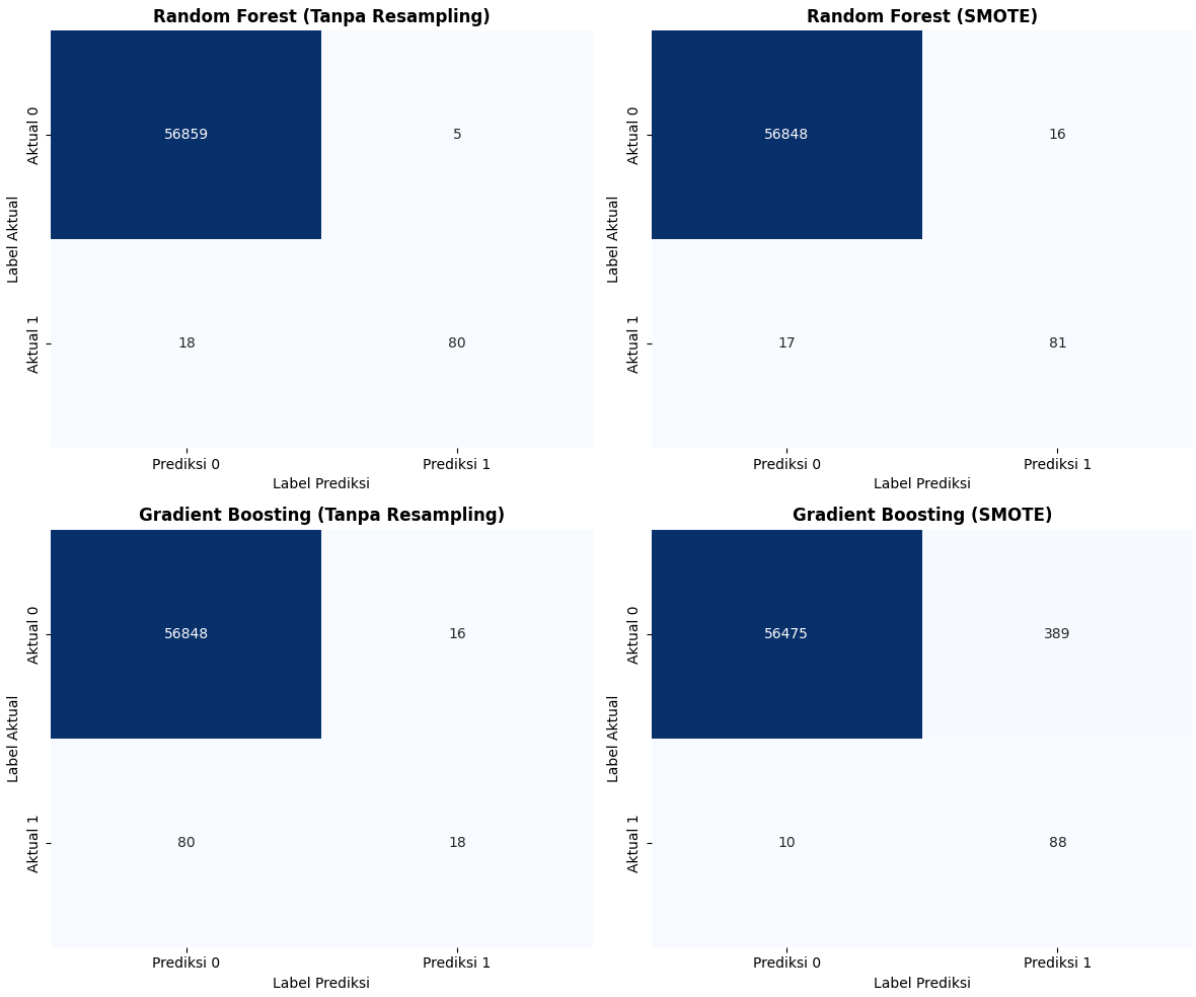
Pada kasus dengan ketimpangan ekstrem seperti ini, penggunaan metrik **Akurasi** sangat menyesatkan (misleading) karena alasan berikut:

1. **Terjebak dalam Accuracy Paradox:** Model naive yang selalu menebak transaksi normal (Kelas 0) akan tetap menghasilkan akurasi sebesar 99,8%, meskipun gagal total mendeteksi satu pun kasus penipuan (fraud).
2. **Mengabaikan Kelas Minoritas:** Akurasi didominasi oleh performa pada kelas mayoritas, sehingga kegagalan mengenali kelas penipuan tidak tampak secara signifikan dalam angka akurasi total.

3. **Konsekuensi Biaya Kesalahan (Cost of Error):** Kesalahan prediksi memiliki dampak nyata yang berbeda:
    - **False Negative (Gagal mendeteksi fraud):** Penjahat lolos dan kerugian finansial terjadi.
    - **False Positive (Menandai transaksi normal sebagai fraud):** Nasabah sah terganggu karena transaksi diblokir.

Oleh karena itu, evaluasi wajib berfokus pada metrik yang menilai kelas minoritas seperti **Precision, Recall, F1-Score, dan AUC-ROC**.

Untuk memahami distribusi prediksi secara mendalam, Confusion Matrix dari keempat model disajikan pada **Gambar 2**.




Gambar 2: Matriks kebingungan (Confusion Matrix) untuk Random Forest dan Gradient Boosting, baik tanpa resampling maupun dengan penerapan SMOTE

**Analisis dan Pembahasan Perbandingan:**

1. **Random Forest:**
    - **Tanpa Resampling:** Menghasilkan Precision yang sangat tinggi (0,9412) dengan Recall 0,8163. Berdasarkan matriks kebingungan, model ini hanya menghasilkan sedikit False Positive (5 kasus), namun melewatkan 18 kasus fraud (False Negative).
    - **Dengan SMOTE:** Penggunaan SMOTE sedikit meningkatkan kemampuan tangkap (Recall naik menjadi 0,8265 dengan 81 kasus tertangkap), namun menurunkan Precision (menjadi 0,8351) karena jumlah False Positive meningkat menjadi 16 kasus. Secara keseluruhan, performa Random Forest sangat stabil bahkan tanpa resampling.

2. **Gradient Boosting:**
    - **Tanpa Resampling:** Model menunjukkan performa yang sangat buruk pada data minoritas, dengan Recall hanya 0,837% (hanya 18 dari 98 kasus fraud di data uji yang tertangkap) dan AUC-ROC yang rendah (0,3469).
    - **Dengan SMOTE:** Perubahan drastis terjadi setelah penerapan SMOTE. Recall melonjak signifikan hingga **0,8980** (berhasil menangkap 88 dari 98 kasus fraud), dan AUC-ROC meningkat menjadi 0,7978.
    - **Trade-off (Precision vs Recall):** Lonjakan Recall pada Gradient Boosting dengan SMOTE harus dibayar dengan penurunan Precision yang cukup besar (turun menjadi 0,1845) akibat tingginya jumlah False Positive (389 kasus transaksi normal salah ditandai sebagai fraud). Hal ini menunjukkan bahwa SMOTE membuat model menjadi lebih sensitif dalam mendeteksi kelas minoritas, namun memunculkan lebih banyak alarm palsu.