

LAPORAN PRAKTIKUM 2: PRAPROSES DATA

Nama: Muhammad Zaki Nanda Wahyudi

NRP: 5054251007

Dataset: House Prices - Advanced Regression Techniques (train.csv)

1. PENDAHULUAN & RINGKASAN DATASET

1.1 Deskripsi Tugas

Praproses data (*data preprocessing*) merupakan tahapan paling krusial dalam siklus pengembangan model *Machine Learning* untuk meningkatkan kualitas data, menangani *missing values*, serta mentransformasikan data agar sesuai dengan asumsi algoritma. Pada praktikum ini, dilakukan serangkaian proses praproses terhadap dataset *House Prices: Advanced Regression Techniques* dari Kaggle.


1.2 Struktur Data Awal

Dataset awal (train.csv) memuat **1.460 baris** dan **81 kolom**, yang terdiri dari:

- **Fitur Identitas:** Id (1 kolom).
- **Fitur Target:** SalePrice (1 kolom numerik kontinu).
- **Fitur Prediktor:** 79 kolom kombinasi numerik (kontinu/diskrit) dan kategorikal (nominal/ordinal).

2. METODOLOGI & LANGKAH-LANGKAH PRAPROSES DATA

Praproses data dilakukan secara sistematis dalam 5 tahapan utama:



2.1 Tahap 1: Pembersihan Data (Data Cleaning)

1. Penanganan *Missing Values*:

- **Aturan Eliminasi Kolom (> 50% Missing):** Kolom PoolQC, MiscFeature, Alley, Fence, dan FireplaceQu yang memiliki persentase data hilang lebih dari 50% dihapus dari dataset untuk mencegah bias dan imputasi yang terlalu spekulatif.
- **Imputasi Kategorikal:** Untuk fitur fisik rumah seperti GarageType, BsmtQual, BsmtCond, dll., nilai NaN bukan merupakan *missing data* secara acak, melainkan menandakan ketidakadaan fasilitas tersebut. Oleh karena itu, diimputasi dengan nilai kustom 'None'.
- **Imputasi Numerik:** Fitur numerik kontinu seperti LotFrontage diimputasi menggunakan nilai **median** berdasarkan kelompok lingkungan (Neighborhood) untuk memperhitungkan variasi spasial.


2. Koreksi Tipe Data:

- Kolom seperti MSSubClass yang bernilai angka diubah menjadi tipe string/object karena mewakili kategori jenis bangunan (*sub-class*), bukan variabel pengukuran kuantitatif.

2.2 Tahap 2: Deteksi & Penanganan Outlier

1. Deteksi Outlier via Visualisasi & Boxplot:

- Berdasarkan saran dokumentasi resmi Kaggle dan eksplorasi *boxplot* antara fitur GrLivArea (luas area tinggal di atas tanah) dan SalePrice, terdeteksi dua sampel dengan area sangat luas (> 4.000 sq ft) namun dijual dengan harga yang sangat murah (< \$300.000).



2. Keputusan Penanganan:

- Dua observasi *outlier* ekstrem ini dieliminasi dari dataset karena berpotensi merusak garis regresi linier dan mendistorsi pemodelan berbasis jarak.
- **Hasil setelah penghapusan *outlier*:** Jumlah baris berkurang dari **1.460** menjadi **1.458 baris**.

2.3 Tahap 3: Transformasi Data & Feature Encoding

1. One-Hot Encoding (OHE):

- Seluruh fitur kategorikal diubah menjadi representasi biner (*dummy variables*) menggunakan `pd.get_dummies(drop_first=True)`.
- Tahap ini mengubah fitur teks kategorikal menjadi numerik yang siap diproses oleh model ML.


- Bentuk Dataframe setelah OHE: (1.458 baris, 241 kolom).

2. Standarisasi Fitur (StandardScaler):

- Sebelum dilakukan *Principal Component Analysis* (PCA), seluruh fitur prediktor numerik dipisahkan dari target SalePrice dan kolom Id.
- Dilakukan transformasi Z-score ($\mu = 0, \sigma = 1$) menggunakan `StandardScaler()` agar fitur dengan skala besar (seperti LotArea) tidak mendominasi fitur berskala kecil dalam analisis komponen utama.

2.4 Tahap 4: Reduksi Dimensi (Multikolinearitas & PCA)

1. Penanganan Multikolinearitas (Analisis Korelasi):



- Evaluasi matriks korelasi menunjukkan beberapa pasangan fitur memiliki nilai *Pearson correlation coefficient* berlebihan ($r > 0.80$):
 - TotalBsmtSF ↔ 1stFlrSF ($r = 0.8054$)
 - GrLivArea ↔ TotRmsAbvGrd ($r = 0.8339$)
 - GarageCars ↔ GarageArea ($r = 0.8873$)
- **Fitur yang dibuang:** ['1stFlrSF', 'TotRmsAbvGrd', 'GarageArea'] untuk menghilangkan redundancies sebelum proses PCA.

2. Principal Component Analysis (PCA):

- Algoritma PCA diterapkan dengan parameter `n_components=0.90` untuk mempertahankan **90% kumulatif varians** dari data.
- **Hasil PCA:** Dimensi fitur berhasil dipangkas dari **239 fitur awal** menjadi **131 Principal Components (PC_1 s.d. PC_{131})** dengan total akumulasi varians sebesar **90.03%**.

3. HASIL DAN VISUALISASI


3.1 Ringkasan Transformasi Dataset

Tahapan Praproses	Jumlah Baris	Jumlah Kolom / Fitur	Keterangan Singkat
Dataset Awal	1.460	81	Memuat <i>missing values</i> & <i>outlier</i>
Pembersihan Outlier	1.458	81	Mengeliminasi 2 <i>outlier</i> ekstrem GrLivArea > 4000
Drop Missing > 50%	1.458	76	Menghapus 5 kolom kualitatif kosong

Tahapan Praproses	Jumlah Baris	Jumlah Kolom / Fitur	Keterangan Singkat
Reduksi Korelasi	1.458	73	Menghapus 3 kolom multikolinearitas tinggi
One-Hot Encoding	1.458	241	Transformasi variabel kualitatif ke biner
PCA (Varians 90%)	1.458	132	131 Komponen Utama + 1 Target (SalePrice)

3.2 Visualisasi Akumulasi Varians PCA (Scree Plot)

Di bawah ini adalah kurva *Scree Plot* yang menggambarkan hubungan antara jumlah *Principal Components* yang dipilih dengan kumulatif rasio varians data yang berhasil dipertahankan:



4. KESIMPULAN & HASIL AKHIR DATASET

1. **Kualitas Data:** Dataset telah bersih dari nilai hilang (*missing values*) dan *outlier* ekstrem, serta telah disesuaikan skala fiturnya.
2. **Efisiensi Dimensi:** Melalui kombinasi reduksi korelasi dan PCA, dimensi dataset berhasil dikurangi hingga **~45% dari fitur terencode awal** (dari 239 fitur menjadi 131 komponen) tanpa kehilangan lebih dari 10% informasi penting (90.03% varians dipertahankan).
3. **Penyimpanan Dataset Akhir:**
 - Dataframe hasil akhir digabungkan kembali dengan variabel target SalePrice.
 - File disimpan dengan nama Dataset_final.csv dengan matriks ukuran **(1458, 132)** dan siap digunakan untuk pemodelan *Machine Learning* (seperti Regresi Linier, Ridge/Lasso, Random Forest, atau XGBoost).