

Laporan Tugas Scrapping dan EDA

1. Pendahuluan dan Pengumpulan Data

- Sumber Data: <https://myanimelist.net/topanime.php>
- Metode Pengumpulan: Web scraping menggunakan Python (*requests* dan *BeautifulSoup*)
- Ukuran Dataset: 2.000 baris dan 7 kolom

2. Pemahaman dan Klasifikasi Atribut Dataset

Berikut adalah struktur dan tipe data dari 7 atribut yang dianalisis:

Nama Atribut	Tipe Data	Tipe Atribut	Keterangan
Rank	int64	Ordinal	Tingkatan/posisi peringkat anime
Title	str	Nominal	Judul/nama anime
Type	str	Nominal	Format tayang (TV, Movie, ONA, dst)
Episodes	float64	Numerik Diskrit	Jumlah total episode anime
Start_Year	int64	Numerik Diskrit	Tahun rilis anime
Score	float64	Numerik Kontinu	Rating anime (skala 1,00 – 10,00)
Members	int64	Numerik Diskrit	Jumlah user yang menambahkan anime ke list

3. Analisis Kualitas Data dan Statistik Deskriptif

a. Missing Values

- Atribut **episodes** memiliki 14 missing value (0,7%) karena status tayang anime yang belum selesai/belum dikonfirmasi. Atribut lain tidak memiliki missing value

b. Deteksi dan Handling Outlier

- Outlier terdeteksi: Episodes (142 data), Start_Year (129 data), Score (27 data), dan Members (221 data)
- Penanganan data: Outlier dipertahankan (tidak dihapus) karena merupakan natural outliers, seperti anime dengan durasi sangat Panjang (One Piece), anime klasik sebelum era 1987, atau anime dengan rating sangat tinggi

4. Visualisasi Data dan Temuan Utama

a. Analisis Univariat

- Distribusi score: Miring ke kanan (right-skewed). Lebih dari 300 anime berada pada rentang skor 7,5 – 7,8, sedangkan skor di atas 8,8 sangat langka
- Distribusi type: Serial TV mendominasi dataset (>1.000 anime), diikuti oleh format movie (>400 anime)

b. Analisis Bivariat

- Members vs Score: Menunjukkan tren positif. Anime dengan popularitas di atas 1-2 juta members hampir seluruhnya memiliki score tinggi ($>8,0$)
- Score per Type: Format TV dan Movie memiliki median score tertinggi (sekitar 7,9). Titik outlier score tinggi paling banyak ditemukan pada tipe TV

c. Analisis Korelasi (Heatmap)

- Rank vs Score (-0,95): Korelasi negatif sangat kuat. Semakin kecil nilai rank (peringkat teratas), semakin tinggi score-nya
- Members vs Score (0,38): Korelasi positif sedang. Popularitas cenderung sejalan dengan persepsi kualitas (score)
- Rank vs Members (-0,34): Korelasi negatif sedang. Anime peringkat atas cenderung menarik lebih banyak members

5. Kesimpulan

- a. Format serial TV adalah kontributor terbanyak sekaligus pemilik rating rata-rata tertinggi pada jajaran Top anime di MyAnimeList
- b. Popularitas (Members) berbanding lurus dengan rating (Score), meskipun ada beberapa anime klasik yang memiliki popularitas yang rendah namun skornya tinggi
- c. Kualitas dataset sangat baik dengan tingkat missing value sangat kecil ($<1\%$) dan pola outlier yang mencerminkan kondisi nyata di lapangan