Laporan Analisis Sequential Pattern: Dataset Online Retail

Tugas Data Mining · Muhammad Zaki Nanda Wahyudi (5054251007)

1. Eksplorasi dan Pembersihan Data

Dataset mentah berisi 541.909 baris dan 8 kolom (InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, Country), dengan 25.900 invoice, 4.372 pelanggan unik, dan 4.223 deskripsi produk unik. Dua kolom memiliki nilai kosong: Description (1.454 baris) dan CustomerID (135.080 baris). Empat kolom dipakai untuk analisis pola berurutan: **CustomerID** (satu pelanggan = satu sequence), **InvoiceNo** (satu invoice = satu itemset), **InvoiceDate** (urutan waktu), dan **Description** (item produk).

Pembersihan dilakukan dalam empat langkah berikut.

Langkah	Baris dihapus	Sisa baris
Data awal	-	541.909
Hapus Description kosong	1.454	540.455
Hapus invoice batal (awalan "C")	9.288	531.167
Hapus Quantity ≤ 0	474	530.693
Hapus CustomerID kosong	132.769	397.924

Ukuran	Sebelum	Sesudah	Dihapus
Jumlah baris	541.909	397.924	143.985
Jumlah invoice	25.900	18.536	7.364
Jumlah pelanggan	4.372	4.339	33

Total 143.985 baris (26,6%) dibuang. Sebagian besar (92%) karena CustomerID kosong, yang wajib dihapus karena sequence disusun per pelanggan. Dampaknya pada jumlah pelanggan kecil: hanya 33 pelanggan (0,8%) yang hilang, yaitu pelanggan yang seluruh barisnya tidak valid.

2. Penyusunan Sequence

Data diurutkan menurut CustomerID dan InvoiceDate, lalu item dalam satu invoice digabung menjadi satu itemset (item duplikat dalam invoice dibuang). Hasilnya 18.566 itemset; angka ini sedikit lebih besar dari jumlah invoice (18.536) karena 30 invoice memiliki lebih dari satu stempel waktu sehingga terpecah menjadi beberapa itemset. Itemset tiap pelanggan kemudian disusun berurutan waktu menjadi **4.339 sequence**.

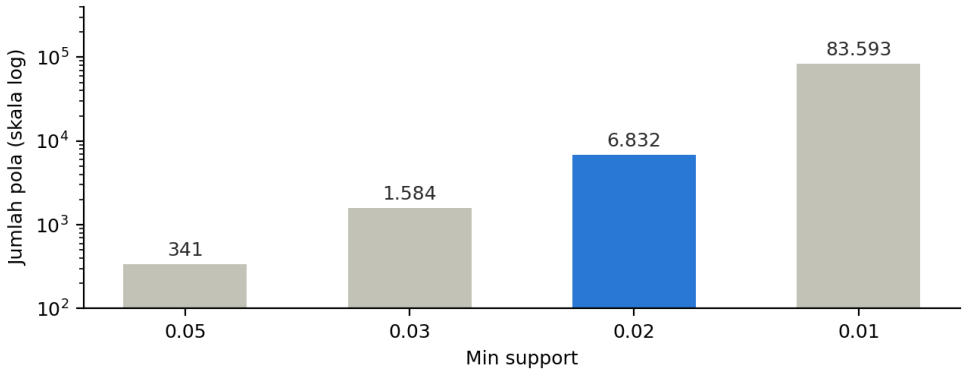
Rata-rata pelanggan memiliki 4,28 invoice (median 2), dan 1.492 pelanggan (34,4%) hanya punya satu invoice sehingga tidak berkontribusi pada pola berurutan. Satu invoice rata-rata memuat 20,9 produk (median 15). Karena PrefixSpan hanya menerima item tunggal, itemset diratakan menjadi satu daftar per pelanggan, dengan item dalam satu invoice berurutan secara alfabet.

3. Pemilihan Parameter

Algoritma yang dipakai adalah PrefixSpan dengan panjang pola dibatasi maksimal 3 item. Empat nilai minimum support (relatif terhadap jumlah pelanggan) dibandingkan.

Min support	Min pelanggan	Jumlah pola	Waktu (detik)
0,05	216	341	6,0
0,03	130	1.584	18,2

Min support	Min pelanggan	Jumlah pola	Waktu (detik)
0,02	**86**	**6.832**	**44,0**
0,01	43	83.593	157,6



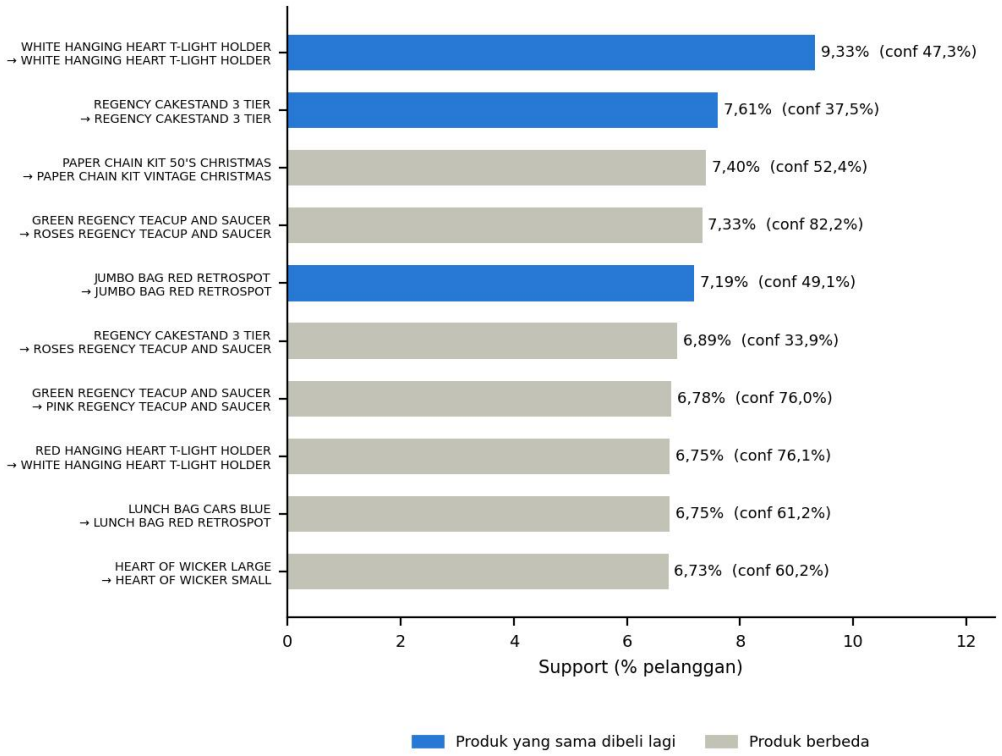
Jumlah pola menurut min support (skala logaritmik). Batang biru = nilai terpilih.

Dipilih **min support 0,02** (86 pelanggan). Menurunkan nilai ke 0,01 membuat pola melonjak sekitar 12 kali lipat (83.593 pola) dan waktu proses naik menjadi 157,6 detik, sementara batasnya hanya 43 pelanggan sehingga banyak pola yang berpotensi muncul karena kebetulan dan sulit diinterpretasi. Nilai 0,05 menghasilkan hanya 341 pola sehingga variasinya terbatas. Pada 0,02 tersedia 6.832 pola yang masih dapat dianalisis dengan dukungan minimal 86 pelanggan.

4. Pola Berurutan dan Evaluasi

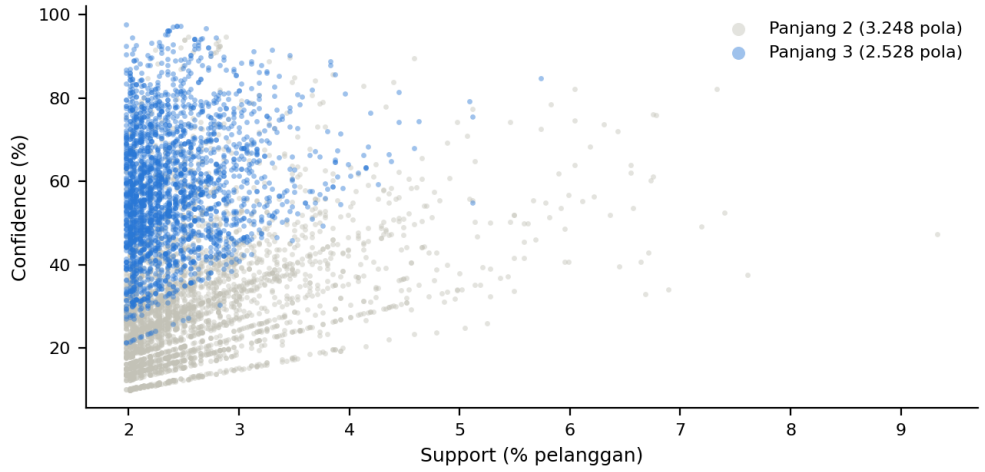
Pada parameter terpilih ditemukan **6.832 pola**: 1.056 berisi satu item, 3.248 berisi dua item, dan 2.528 berisi tiga item. Support = jumlah pelanggan yang memiliki pola tersebut dalam sequence-nya, sedangkan confidence = support pola lengkap dibagi support prefix-nya (misalnya support(A→B) / support(A)). Confidence hanya dapat dihitung untuk pola ≥ 2 item, yaitu 5.776 pola; ringkasannya:

Ukuran	Minimum	Rata-rata	Maksimum
Support (% pelanggan)	1,98%	2,54%	9,33%
Confidence	9,9%	43,5%	97,7%



Sepuluh pola berurutan dengan support tertinggi. Label di bar: support dan confidence.

#	Pola berurutan	Support	Support (%)	Conf. (%)
1	WHITE HANGING HEART T-LIGHT HOLDER → WHITE HANGING HEART T-LIGHT HOLDER	405	9,33	47,3
2	REGENCY CAKESTAND 3 TIER → REGENCY CAKESTAND 3 TIER	330	7,61	37,5
3	PAPER CHAIN KIT 50'S CHRISTMAS → PAPER CHAIN KIT VINTAGE CHRISTMAS	321	7,40	52,4
4	GREEN REGENCY TEACUP AND SAUCER → ROSES REGENCY TEACUP AND SAUCER	318	7,33	82,2
5	JUMBO BAG RED RETROSPOT → JUMBO BAG RED RETROSPOT	312	7,19	49,1
6	REGENCY CAKESTAND 3 TIER → ROSES REGENCY TEACUP AND SAUCER	299	6,89	33,9
7	GREEN REGENCY TEACUP AND SAUCER → PINK REGENCY TEACUP AND SAUCER	294	6,78	76,0
8	RED HANGING HEART T-LIGHT HOLDER → WHITE HANGING HEART T-LIGHT HOLDER	293	6,75	76,1
9	LUNCH BAG CARS BLUE → LUNCH BAG RED RETROSPOT	293	6,75	61,2
10	HEART OF WICKER LARGE → HEART OF WICKER SMALL	292	6,73	60,2



Sebaran support dan confidence dari seluruh pola berpanjang ≥ 2.

Evaluasi tiga pola dengan support tertinggi.

1. WHITE HANGING HEART T-LIGHT HOLDER → WHITE HANGING HEART T-LIGHT HOLDER (support 9,33%, confidence 47,31%) dan **2. REGENCY CAKESTAND 3 TIER → REGENCY CAKESTAND 3 TIER** (7,61%, 37,46%) adalah pola pembelian berulang: produk yang sama dibeli lagi pada invoice berikutnya. Item duplikat dalam satu invoice sudah dibuang, sehingga pengulangan ini terjadi antar invoice. Hampir separuh pembeli T-light holder membelinya kembali, menandakan produk dengan perputaran tinggi yang stoknya perlu dijaga.

3. PAPER CHAIN KIT 50'S CHRISTMAS → PAPER CHAIN KIT VINTAGE CHRISTMAS (7,40%, 52,37%) adalah pola lintas varian dengan confidence tertinggi di antara tiga besar. Lebih dari separuh pembeli varian pertama kemudian membeli varian kedua; produknya bersifat musiman sehingga relevan untuk bundling dan persiapan stok menjelang Natal.

Pola lain yang menonjol.

Set cangkir Regency: GREEN → ROSES (7,33%, confidence 82,2%) dan pola tiga item GREEN → PINK → ROSES TEACUP AND SAUCER (support 5,74%, confidence 84,7%) menunjukkan pelanggan melengkapi koleksi warna secara bertahap.

Confidence tertinggi muncul pada pola satu seri produk, misalnya HERB MARKER CHIVES → HERB MARKER ROSEMARY → HERB MARKER THYME (support 2,47%, confidence 97,3%), tetapi dengan support lebih kecil sehingga berlaku untuk segmen pembeli tertentu.

Sebanyak 162 pola berupa pembelian ulang produk yang sama, sedangkan sisanya berupa kombinasi varian atau produk sejenis dalam satu seri (cangkir Regency, tas Jumbo, lunch bag, dan sebagainya).

5. Kesimpulan

Pembersihan menghapus 143.985 baris (26,6%) sehingga tersisa 397.924 baris dari 4.339 pelanggan, yang disusun menjadi 4.339 sequence. Dengan PrefixSpan, min support 0,02 (86 pelanggan), dan panjang pola maksimal 3, ditemukan 6.832 pola, dengan 5.776 pola berpanjang ≥ 2 yang dievaluasi menggunakan support dan confidence.

Pola pembelian berurutan yang paling konsisten ada dua. **Pertama**, pembelian berulang produk yang sama, terutama T-light holder, cakestand, dan jumbo bag, yang mengindikasikan produk dengan permintaan berulang. **Kedua**, pembelian bertahap varian dalam satu seri, misalnya cangkir Regency (Green → Pink → Roses), kit paper chain, dan lunch bag, yang mengindikasikan pelanggan melengkapi koleksi.

Secara bisnis, pola ini mendukung pengingat atau penawaran restock bagi pembeli produk berulang, bundling dan rekomendasi varian lain dalam satu seri, serta penyiapan stok produk musiman lebih

awal.

Keterbatasan: (1) item dalam satu invoice diratakan secara alfabet, sehingga pola A → B antar produk berbeda dapat terjadi pada invoice yang sama, bukan hanya invoice berbeda; (2) panjang pola dibatasi 3 item; (3) 132.769 baris tanpa CustomerID tidak dapat dianalisis; (4) support pola berkisar 1,98–9,33%, sehingga berlaku pada segmen pembeli tertentu, dan dataset ini didominasi pelanggan United Kingdom serta kemungkinan memuat pembeli grosir; (5) pola menunjukkan keterkaitan urutan pembelian, bukan sebab-akibat.